

Orbital Solar Insight

IA e Machine Learning aplicados a dados de observação da Terra

● Energia solar urbana · Perfis climáticos regionais · Fonte: NASA POWER

ODS 9

Indústria & Inovação

ODS 11

Cidades Sustentáveis

ODS 13

Ação Climática

O problema



Brasil heterogêneo

5

regiões e biomas com climas radicalmente diferentes — da Amazônia úmida ao Nordeste seco e Sul temperado.



Planejamento exige dados

Energia e adaptação climática urbana dependem de séries confiáveis e espacialmente distribuídas.



Vazios na rede de superfície

INMET concentra estações no Sul/Sudeste; Norte e Centro-Oeste ficam mal cobertos.



Satélite resolve o vazio

Cobertura global e uniforme — preenche regiões sem instrumentação adequada.

Perguntas de pesquisa

Q1 • SUPERVISIONADO



Previsão de irradiância solar diária

Estimar a irradiância nas capitais brasileiras com erro suficiente para dimensionar sistemas fotovoltaicos.

Q4 • NÃO-SUPERVISIONADO



Agrupamento por perfil climático

Agrupar capitais por perfil climático para apoiar políticas públicas regionalizadas.

Por que as duas juntas? Q1 sustenta decisões locais. Q4 sustenta decisões estruturais.



Dataset NASA POWER

10

variáveis diárias

irradiância, T, RH, vento, chuva,
pressão, Kt

12

capitais brasileiras

5 regiões · 5 biomas

43.836

registros diários

janela 2015 – 2024

0

valores faltantes

produto maduro pós-2015



API pública · sem chave · cobertura global

power.larc.nasa.gov/api/temporal/daily/point

Dados de satélite reanalisados — uniformes em todo o território nacional, sem os vazios típicos das redes de superfície. As 12 capitais escolhidas cobrem todos os biomas brasileiros, garantindo representatividade climática.

Pipeline de processamento

1

`data_acquisition.py`



API NASA POWER → CSVs por cidade

3

`eda.py`



6 visualizações: distribuição, sazonalidade, correlação

5

`clustering.py`



KMeans + PCA + análise de silhueta

2

`data_preprocessing.py`



Limpeza + lags + médias móveis + ciclos sin/cos

4

`modeling.py`



Linear / RF / XGBoost · TimeSeriesSplit(5)

6

`main.py`



Orquestrador · idempotente · com cache



Decisões metodológicas

01

Split temporal (últimos 20 %)

Evita vazamento de dados e simula uso operacional em produção.

02

TimeSeriesSplit(5) na validação cruzada

Folds respeitam a ordem temporal — sem look-ahead bias.

03

Features cíclicas (sin/cos do DOY)

Modelos de árvore capturam sazonalidade sem descontinuidade no fim do ano.

04

Lags de 1 e 7 dias


Memória atmosférica curta — persistência é o melhor preditor de curto prazo.

05

One-hot da região

Diferencia regimes climáticos sem precisar treinar um modelo por cidade.

Regressão de irradiância solar



R² e MAPE no teste

Modelo	R²	MAPE
Linear	0,969	6,6 %
Random Forest	0,995	1,7 %
XGBoost	0,998	1,26 %

0,069

kWh/m²/dia ≈ 1,3 % relativo

Mais preciso que a próxima fonte de incerteza (performance ratio FV).

Features que mais explicam (XGBoost)

1

ALLSKY_KT

Índice de claridade do céu

2

CLRSKY_SFC_SW_DWN

Teto físico de irradiância

3

Lags 1d & médias 7d

Persistência atmosférica

4

doy_sin, doy_cos

Componentes cíclicos sazonais

5

RH2M

Umidade relativa — proxy de nuvens




Interpretação

O modelo aprende a física da irradiância sem ser ensinado.

As features mais importantes correspondem exatamente às variáveis que um meteorologista escolheria: claridade, teto físico, persistência, sazonalidade e umidade.

Quantos clusters?

Silhueta média por número de clusters



$k = 4$

Convergência

Cotovelo, silhueta e Calinski-Harabasz apontam o mesmo ótimo.

0,404

Silhueta máxima

Separação moderada — esperado para $n = 12$ cidades.

$n_init = 30$

Estabilidade

Solução estável entre diferentes inicializações aleatórias.

Os quatro Brasis climáticos



0

Amazônia úmida

Manaus · Belém

Temperatura estável · RH 83 % · chuva alta



1

Sul/Sudeste úmido

Porto Alegre · Curitiba · São Paulo · Rio

Temperatura média 20 °C · amplitude térmica alta



2

Litoral Nordeste

Fortaleza · Recife

Solar + vento alto = híbrido ideal



3

Cerrado interior

Brasília · Goiânia · Belo Horizonte · Salvador

RH 69 % · céu limpo · alta Kt

Insight central: a clusterização descobre região e bioma sem usá-los como input.

Interpretação para os ODS

ODS

09

Indústria & Inovação

Q1

Alimenta planejamento de redes — geração estimada por CEP com erro inferior a 2 %.

ODS

11

Cidades Sustentáveis

Q4

Políticas de adaptação podem ser compartilhadas entre cidades do mesmo cluster — racionaliza o esforço técnico.

ODS

13

Ação Climática

Futuro


Série permite, em trabalhos futuros, detectar tendências e anomalias regionais (extensão para Q10).

Limitações honestas



Resolução espacial ~50 km/píxel

Adequado para política regional, não para análise rooftop individual.



Amostra pequena (n = 12 cidades)

Silhueta moderada; com 50 capitais a separação dos clusters seria nítida.



Modelo Q1 é estático (mesmo dia)

Extensão prospectiva é direta com lags adicionais e janela móvel.



Sem grid search exaustivo

Hiperparâmetros default; ganho marginal esperado < 5 %.

Reconhecer limitações é parte do método — cada ponto fraco é um caminho de melhoria documentado.

Como rodar o projeto

• • • terminal

```
# 1. instalar dependências
$ pip install -r requirements.txt

# 2. pipeline completo (download + processamento)
$ python -m src.main

# 3. reexecutar com cache (rápido)
$ python -m src.main --no-download

# 4. notebook espelhado
$ jupyter notebook notebooks/01_analysis.ipynb
```

Saídas geradas

11

PNGs de visualização

1

modelo serializado (.joblib)

8

CSVs de resultados

1

JSON-resumo executivo

Take-aways

~1,3 %

erro relativo de previsão

Dados públicos e gratuitos + ML clássico = previsão solar de qualidade operacional.

5 biomas

recuperados sem rótulo

O satélite carrega a assinatura climática regional — clustering reconstrói biomas sem usá-los como input.

100 %

pipeline reprodutível

Modular, testado, idempotente — um único comando reproduz toda a análise do zero.

→ h+1, h+7

próximo passo

Previsão prospectiva multi-horizonte e cruzamento com dados socioeconômicos.

Obrigado.

Perguntas, comentários e críticas são bem-vindos.



Repositório

github.com/GiantMazelliWasHere/orbital-solar-insight



Fonte de dados

NASA POWER · power.larc.nasa.gov