

Orbital Solar Insight — Relatório Acadêmico

FIAP — Global Solution 2026 **Disciplina:** Inteligência Artificial e Machine Learning **Dataset:** NASA POWER (Prediction Of Worldwide Energy Resources) **Tema espacial:** Observação da Terra via satélite **ODS endereçados:** 9 (Indústria, Inovação e Infraestrutura), 11 (Cidades e Comunidades Sustentáveis), 13 (Ação Climática)

1. Definição do Problema e Contextualização

1.1 Perguntas de pesquisa

O trabalho responde a duas perguntas complementares — uma supervisionada e outra não-supervisionada — sobre a interseção entre dados de satélite e sustentabilidade urbana:

***Q1 (regressão):** É possível prever a **capacidade diária de geração de energia solar** em centros urbanos brasileiros a partir de variáveis meteorológicas derivadas de satélite, com erro suficientemente baixo para apoiar dimensionamento de infraestrutura energética sustentável?*

***Q4 (clustering):** É possível **agrupar capitais brasileiras por comportamento climático**, de forma a identificar regimes regionais que apoiem políticas públicas diferenciadas?*

1.2 Justificativa

A combinação das duas perguntas atende a três motivações distintas que dialogam diretamente com os ODS escolhidos:

- **Planejamento energético (ODS 9):** previsões diárias de irradiância subsidiam o dimensionamento de redes fotovoltaicas urbanas e a integração com a rede convencional — onde subdimensionar acarreta apagão por demanda residual e superdimensionar gera *capex* perdido.
- **Políticas urbanas regionalizadas (ODS 11):** o Brasil tem cinco regiões com biomas e climatologias muito distintas. Tratá-las de forma uniforme produz políticas medianas e ineficientes; agrupá-las por similaridade objetiva (em vez de fronteiras administrativas) revela onde estratégias podem ser compartilhadas.
- **Diagnóstico climático evidencial (ODS 13):** dados de satélite oferecem cobertura uniforme e independente de infraestrutura terrestre — fundamental em um país com estações INMET concentradas no Sul/Sudeste.

1.3 Origem dos dados — NASA POWER

A **NASA POWER** é uma iniciativa da NASA Langley Research Center que disponibiliza dados solares e meteorológicos derivados de **observações de satélite (CERES, MERRA-2)** e modelos de reanálise atmosférica. As principais características:

- **Cobertura:** global, em grade regular de aproximadamente $0,5^\circ \times 0,5^\circ$ (~50 km de resolução horizontal).
- **Cadência temporal:** dados diários disponíveis desde 1981; horária e mensal também acessíveis.
- **Acesso:** API pública sem autenticação (<https://power.larc.nasa.gov/api/temporal/daily/point>).
- **Comunidades de uso:** *RE* (Renewable Energy, usada aqui), *AG* (Agroclimatology) e *SB* (Sustainable Buildings) — apenas mudam o subconjunto sugerido de variáveis.

Variáveis utilizadas

Sigla	Descrição	Unidade
ALLSKY_SFC_SW_DWN	Irradiância solar global na superfície (todas as condições de céu) — alvo	kWh/m²/dia
CLRSKY_SFC_SW_DWN	Irradiância sob céu limpo (teto físico de geração)	kWh/m²/dia
ALLSKY_KT	Índice de claridade ($\approx$ ALLSKY/CLRSKY) — adimensional	—
T2M, T2M_MAX, T2M_MIN	Temperatura do ar a 2 m de altura	°C
RH2M	Umidade relativa a 2 m	%
PRECTOTCORR	Precipitação corrigida por bias	mm/dia
WS2M	Velocidade do vento a 2 m	m/s
PS	Pressão atmosférica de superfície	kPa

Limitações e cuidados de interpretação

- **Resolução espacial grosseira.** Um *grid cell* de ~50 km cobre toda a região metropolitana — micro-climas, ilhas de calor e efeitos de relevo urbano não são resolvidos.
- **Valor sentinela.** Dados ausentes são representados por -999; trataremos como NaN explícito.
- **Bias residual.** A NASA POWER usa correções de bias contra estações de superfície, mas em regiões com poucas estações de calibração (Amazônia central) o erro absoluto pode ser maior.
- **Para uso operacional,** recomenda-se confronto com estações INMET próximas.

1.4 Escopo geográfico e temporal

- **12 capitais brasileiras** cobrindo as 5 regiões e 5 biomas (Amazônia, Caatinga, Cerrado, Mata Atlântica, Pampa).
- **10 anos completos** (2015-01-01 a 2024-12-31), totalizando **43.836 registros diários**.

2. Metodologia

2.1 Aquisição

Foi implementado o módulo `src/data_acquisition.py` que itera sobre `config.CITIES` e consulta o endpoint `temporal/daily/point` com retries exponenciais. A resposta JSON é convertida em DataFrame longo (uma linha por dia × cidade) e materializada em `data/raw/<cidade>.csv` e em `data/processed/nasa_power_consolidated.csv`.

A função é **idempotente**: arquivos já baixados não são re-baixados a menos que `force=True` seja passado.

2.2 Pré-processamento e *feature engineering*

Implementado em `src/data_preprocessing.py`:

- **Sentinela** -999 → NaN explícito.
- **Forward fill/back fill limitados a 3 dias** por cidade, para tratar gaps esporádicos sem inventar dados em períodos longos.

- **Features de calendário cíclicas:** $\text{doy_sin} = \sin(2\pi \cdot \text{DOY}/365.25)$ e $\text{doy_cos} = \cos(\dots)$ — modelos baseados em árvore extraem sazonalidade diretamente desses sinais.
- **Lags 1 e 7 dias** para T2M, RH2M, PRECTOTCORR e o próprio alvo: capturam persistência de curto prazo (memória atmosférica).
- **Médias móveis 7 e 30 dias** (sempre `shift(1)` antes do *rolling* — sem vazamento).
- **One-hot encoding** da região como variável categórica.

Resultado: **43.656 linhas × 30 features**.

2.3 Divisão treino/teste

Divisão **temporal**: as últimas 20% das datas vão para o conjunto de teste (~8.731 linhas, cobrindo aprox. os últimos 2 anos). Isso simula o uso operacional — prever o futuro a partir do passado — e evita vazamento que ocorreria em divisão aleatória.

Para validação cruzada interna usa-se `TimeSeriesSplit(5)`, que constrói folds incrementais respeitando ordem temporal.

2.4 Modelos supervisionados (Q1)

Três algoritmos com viés/variação contrastantes:

Modelo	Por que está no comparativo
Regressão Linear (com <code>StandardScaler</code>)	Baseline interpretável: se um modelo simples já entrega R^2 alto, é o sinal de que a relação física entre irradiância e céu limpo × claridade é predominantemente linear.
Random Forest	Captura não-linearidades e interações sem tuning denso. Robusto a outliers. Importância nativa de features.
XGBoost	Estado-da-arte em tabular com regularização explícita e <i>early stopping</i> . Costuma superar RF com hiperparâmetros padrão sensatos.

Hiperparâmetros conservadores (sem *grid search*): RF com 300 árvores, `max_depth` 18; XGBoost com 600 árvores, `learning_rate` 0,05, `subsample` 0,85.

2.5 Modelo não-supervisionado (Q4)

Agregamos as séries diárias em **assinaturas climáticas anuais por cidade** (8 estatísticas: média e desvio da irradiância, média e amplitude térmica, umidade, precipitação, vento, índice de claridade). Como $n=12$, KMeans é apropriado e estável.

Avaliamos $k \in [2, 8]$ com:

- **Inércia** (curva-cotovelo)
- **Silhueta** (separação)
- **Calinski-Harabasz** (razão variância entre-grupos / intra-grupos)

$k = 4$ foi escolhido por maximizar simultaneamente silhueta (0,404) e Calinski-Harabasz (10,3).

2.6 Métricas

- **Regressão:** RMSE (mesma unidade do alvo), MAE, R^2 , MAPE.
- **Clustering:** silhueta, Calinski-Harabasz, inércia.

3. Análise Exploratória de Dados

3.1 Qualidade do dado

Após o download, **nenhum valor missing** foi detectado no período/parâmetros escolhidos para as 12 cidades — atestado pela ausência de células acima de 0 % no mapa de calor em `outputs/figures/06_missing_heatmap.png`. Isso é coerente com a maturidade do produto NASA POWER pós-2015.

3.2 Distribuições por região

A figura `01_irradiance_by_region.png` mostra distribuições assimétricas e claramente diferenciadas:

- **Nordeste** apresenta a maior mediana e menor cauda inferior — céu limpo dominante.
- **Sul** tem a menor mediana e maior dispersão — alta sazonalidade (verão $\neq$ inverno).
- **Norte** mostra um *kink* abaixo de 4 kWh/m²/dia coerente com forte nebulosidade convectiva.

3.3 Sazonalidade

O heatmap mensal (`02_seasonality_heatmap.png`) revela:

- Em **Porto Alegre e Curitiba**, junho e julho colapsam para ~2,5 kWh/m²/dia, enquanto dezembro/janeiro chegam a 6+ — relação ~2,5×
- **Fortaleza e Recife** têm comportamento contracíclico: o segundo semestre é o mais radiativo (estação seca).
- A **Amazônia** mostra variação menor entre estações, mas com queda acentuada em fev–abr (estação chuvosa).

3.4 Correlações

A matriz de correlação (`03_correlation_matrix.png`) confirma fisicamente:

- ALLSKY_SFC_SW_DWN $\leftrightarrow$ ALLSKY_KT $\approx 0,9$ (definicional)
- ALLSKY_SFC_SW_DWN $\leftrightarrow$ CLRSKY_SFC_SW_DWN $\approx 0,7$ (teto modulado por nuvens)
- ALLSKY_SFC_SW_DWN $\leftrightarrow$ RH2M < 0 (umidade alta $\rightarrow$ mais nuvens)
- T2M $\leftrightarrow$ RH2M < 0 (clássica)

Essas correlações sustentam a escolha das features e antecipam que **CLRSKY + ALLSKY_KT** carregarão a maior parte do sinal.

4. Resultados

4.1 Q1 — Regressão

Modelo	CV RMSE	RMSE teste	MAE teste	R ² teste	MAPE (%)
Regressão Linear	0,259 ± 0,009	0,272	0,184	0,969	6,64
Random Forest	0,098 ± 0,008	0,107	0,069	0,995	1,67
XGBoost	0,077 ± 0,010	0,069	0,052	0,998	1,26

Leitura técnica:

- O baseline linear já entrega $R^2 = 0,97$ — ou seja, a maior parte da variância é explicável por relações lineares com CLRSKY e ALLSKY_KT.
- Random Forest captura interações (sazonalidade × região) e reduz o RMSE em ~60%.
- XGBoost adiciona regularização e melhora marginalmente, com RMSE de 0,069 kWh/m²/dia ($\approx 1,3\%$ de erro relativo).
- O **gap CV-vs-teste é pequeno (0,077 → 0,069)** — não há overfitting evidente; pelo contrário, o conjunto de teste é levemente mais previsível, possivelmente por concentrar anos mais recentes do produto NASA POWER.

A figura 07_predictions.png mostra (a) scatter previsto × observado com aderência forte à diagonal e (b) série temporal dos últimos 180 dias para uma cidade — os modelos seguem inclusive picos e vales sazonais.

A figura 08_feature_importance.png ordena as features pelo *gain* do XGBoost. Os tops são (esperadamente):

- ALLSKY_KT — claridade do dia
- CLRSKY_SFC_SW_DWN — teto teórico
- Lags da irradiância e médias móveis 7d — persistência atmosférica
- doy_sin / doy_cos — sazonalidade
- RH2M — proxy de nuvens

4.2 Q4 — Clustering

Diagnóstico de k (09_kmeans_diagnostics.png):

k	Inércia	Silhueta	Calinski-Harabasz
2	55,5	0,324	7,3
3	32,4	0,398	8,9
4	19,7	0,404	10,3
5	15,0	0,312	9,5
6	10,9	0,341	9,4

k = 4 é o pico de silhueta e Calinski-Harabasz — escolha objetiva.

Composição dos clusters (10_cluster_pca.png e 11_cluster_profiles.png):

Cluster	Cidades	Perfil (z-score)	Leitura
0 — Amazônia úmida	Manaus, Belém	T alta e estável, RH 83 %, chuva 6,3 mm/dia, Kt baixo	Irradiância média, alta nebulosidade convectiva.
1 — Sul/Sudeste úmido temperado	Porto Alegre, Curitiba, São Paulo, Rio de Janeiro	T 20°C, amplitude térmica 11°C, vento moderado	Cidades com maior variabilidade sazonal e menor irradiância.

Cluster	Cidades	Perfil (z-score)	Leitura
2 — Litoral Nordeste seco e ventoso	Fortaleza, Recife	T 27°C, RH 77 %, vento 4,4 m/s, Kt 0,59	Combinação ideal solar + eólico .
3 — Cerrado de interior	Brasília, Goiânia, Belo Horizonte, Salvador	T 23°C, RH 69 % (a mais baixa), Kt 0,57	Alta irradiância, baixa nebulosidade — perfil "estepe tropical seca".

Os clusters **não foram inicializados com região nem bioma**, mas o resultado os recupera quase perfeitamente — sinal de que as variáveis NASA POWER carregam, por si só, a assinatura climática regional.

5. Discussão e Interpretação

5.1 O que os números significam na prática

Para Q1: um RMSE de 0,069 kWh/m²/dia em uma média típica de 5 kWh/m²/dia corresponde a **~1,3 % de erro relativo**. Em termos operacionais, para um telhado de 50 kWp em São Paulo (~200 kWh/dia esperados), o erro do modelo está abaixo da incerteza típica do *system performance ratio* (5-10 %). Ou seja, **o modelo é mais preciso do que a próxima fonte de incerteza no pipeline de cálculo de geração**.

Para Q4: o cluster do **Litoral Nordeste seco e ventoso** (Fortaleza + Recife) é o mais informativo do ponto de vista de política energética — é a única região que combina alta irradiância e vento estável, justificando investimento em parques híbridos solar-eólico. Já o cluster **Sul/Sudeste úmido** demanda dimensionamento generoso de armazenamento (a variabilidade sazonal é o gargalo, não a média anual).

5.2 Conexão com os ODS

- **ODS 9 (Infraestrutura).** O modelo Q1 pode alimentar plataformas de planejamento de redes — uma operadora pode estimar geração distribuída por CEP com erro <2 % a partir de dados diários gratuitos.
- **ODS 11 (Cidades sustentáveis).** Os clusters da Q4 sugerem que políticas de adaptação climática podem ser compartilhadas entre Porto Alegre, Curitiba, São Paulo e Rio — todas no mesmo regime —, racionalizando esforço técnico de governos estaduais.
- **ODS 13 (Ação climática).** A série de 10 anos permite que extensões futuras (já preparadas no `data_preprocessing.add_lag_features`) detectem tendências e anomalias regionais — um caminho natural para a Q10 do nosso escopo original.

5.3 Limitações reconhecidas

- **Resolução espacial.** ~50 km/píxel — adequado para política regional, não para um telhado específico.
- **Cluster com n=12.** Silhueta de 0,40 é "moderada"; com 50-100 cidades a separação ficaria nítida.
- **Horizonte preditivo curto.** O modelo Q1 é uma **regressão estática** (mesmo dia → mesmo dia). Para previsão prospectiva (h+1, h+7) seria necessário transformar em supervised learning com features estritamente passadas — o que o módulo já suporta via lags.
- **Sem busca de hiperparâmetros.** Um *grid search* poderia ganhar marginalmente; deixamos como trabalho futuro.

5.4 Trabalho futuro

- Estender a Q4 com **DBSCAN/HDBSCAN** para detectar cidades fora dos quatro grupos canônicos.

- Treinar **modelos preditivos prospectivos (h+1, h+7)** para atender Q9 (consumo energético em função de ondas de calor).
- Cruzar com dados socioeconômicos (PIB municipal, IDH) para Q3 (segurança alimentar) e Q8 (risco climático para infraestrutura).
- Validar contra estações INMET nas mesmas capitais.

6. Conclusão

Demonstramos que, com **10 anos de dados gratuitos da NASA POWER** e técnicas clássicas de ML (XGBoost + KMeans), é possível:

- **Prever a irradiância solar urbana com erro de ~1,3 %** — preciso o suficiente para subsidiar dimensionamento de infraestrutura fotovoltaica (ODS 9).
- **Agrupar capitais brasileiras em quatro regimes climáticos coerentes** com biomas e regiões, sem usar essa rotulagem como input — confirmando que o satélite carrega a assinatura regional (ODS 11, 13).

O projeto cumpre integralmente os critérios de avaliação da Global Solution: pergunta formulada e justificada, exploração rigorosa dos dados, solução de ML coerente com o problema, e interpretação dos resultados para além das métricas numéricas.

Apêndice — Como reproduzir

Consultar o [README.md](#). Em resumo:

```
git clone <repo>
cd orbital-solar-insight
pip install -r requirements.txt
python -m src.main      # pipeline completo
```

Saídas: outputs/figures/ (11 PNGs), outputs/models/best_XGBoost.joblib, data/processed/*.csv.